

Reconhecimento de LIBRAS em Tempo Real via MLP e Normalização Invariante

*Trabalho prático final da disciplina de Inteligência Artificial II

Guilherme Augusto Scaglia, João Pedro Denardo, Pedro Henrique Oliveira de Souza

Engenharia da Computação

Fundação Hermínio Ometto (FHO)

Araras, SP, Brasil

{scaglia, denardo749, pedro1204}@alunos.fho.edu.br

Abstract—Propõe-se um sistema de alta performance para o reconhecimento do alfabeto da Língua Brasileira de Sinais (LIBRAS), fundamentado em uma arquitetura de Redes Neurais Multicamadas (*Multilayer Perceptron* - MLP) e na extração de marcos reguladores (*landmarks*) tridimensionais. A pesquisa estabelece uma ruptura com abordagens baseadas em Redes Recorrentes (LSTM), priorizando a integridade geométrica instantânea das configurações manuais em detrimento da análise de dependência temporal. Tal decisão técnica fundamenta-se na natureza estática do alfabeto manual, onde a modelagem de sequências temporais introduz latência e complexidade algorítmica redundantes. A metodologia compreende o desenvolvimento de um *dataset* autoral com 14.000 amostras e a aplicação de um protocolo de normalização cinemática invariante, o qual estabelece a origem das coordenadas no carpo (pulso) do sinalizador. Os resultados experimentais evidenciam que a arquitetura MLP, aliada à fidelidade geométrica dos dados, atingiu uma acurácia de 99,9%, superando modelos temporais em termos de eficiência computacional e viabilidade para execução em tempo real.

Index Terms—LIBRAS, Redes Neurais Densas, MLP, MediaPipe, Normalização Cinemática, Visão Computacional, Acessibilidade.

I. INTRODUÇÃO

A comunicação eficaz constitui o pilar fundamental da inclusão social e do exercício da cidadania. Todavia, para a comunidade surda, persistem barreiras linguísticas severas decorrentes do conhecimento limitado da Língua Brasileira de Sinais (LIBRAS) por parte da população ouvinte. No campo da Inteligência Artificial, o Reconhecimento de Sinais Isolados (*Isolated Sign Language Recognition* - ISLR) apresenta-se como um desafio complexo de visão computacional, exigindo modelos capazes de capturar a semântica de configurações manuais sob condições variáveis de ambiente.

Conforme discutido por Sarmiento e Ponti [2], um dos maiores entraves na tradução de LIBRAS é a baixa generalização de modelos em cenários *cross-dataset*, onde ruídos de iluminação e oclusões degradam a acurácia de redes neurais dependentes de pixels brutos. Para mitigar tais limitações, este trabalho fundamenta-se na extração de esqueletos (*skeleton-based recognition*), utilizando a biblioteca *MediaPipe Hands* para o mapeamento de 21 marcos regu-

ladores (*landmarks*) tridimensionais. Esta abordagem permite que o aprendizado de máquina foque na morfologia intrínseca do sinal, ignorando contextos visuais irrelevantes e reduzindo drasticamente a dimensionalidade do vetor de entrada.

Diferentemente de sistemas baseados em Redes Neurais Recorrentes (RNN) ou *Long Short-Term Memory* (LSTM) [3], que demandam janelas temporais extensas e elevado custo computacional, propõe-se uma ruptura arquitetural para o reconhecimento do alfabeto manual. A inovação reside na implementação de uma rede *Multilayer Perceptron* (MLP) otimizada, integrada a um pipeline de normalização invariante centrada no carpo (pulso). O sistema utiliza a *stack* tecnológica composta por *Python*, *TensorFlow/Keras* e *Streamlit*, alcançando uma solução que integra predição de alta precisão e síntese de voz (*Text-to-Speech*) via *gTTS*, viabilizando a comunicação bidirecional com latência negligível.

II. FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS

A arquitetura do sistema fundamentou-se em uma revisão bibliográfica de estudos recentes, permitindo um posicionamento crítico quanto à transição de modelos baseados em imagens brutas para modelos geométricos de alta abstração.

A. Extração de Esqueletos e Eficiência

Argumenta-se na literatura [1] que a representação baseada em esqueletos é superior ao processamento de pixels, pois elimina ruídos de iluminação. O presente trabalho adota essa premissa via *MediaPipe Hands*, que infere 21 marcos reguladores em tempo real. **Diferencial Técnico:** Enquanto abordagens correlatas codificam marcos em imagens 2D para processamento via Redes Neurais Convolucionais (CNNs), esta implementação utiliza diretamente tensores de coordenadas cartesianas (x, y, z) . Tal escolha elimina a necessidade de convoluções espaciais, reduzindo a entrada para apenas 63 atributos escalares, o que viabiliza a execução em hardwares de baixo custo (CPUs) com alta taxa de quadros por segundo (FPS).

B. Modelagem Temporal vs. Instantânea

O sistema SLRNet [3] utiliza LSTMs para classificar janelas temporais, atingindo acurácia de 86,7%. No entanto, identifica-se que, para o alfabeto manual e sinais estáticos, a dependência temporal introduz latência e complexidade de treinamento desnecessárias. Optou-se por uma arquitetura MLP que, ao focar na geometria instantânea de alta fidelidade, elevou a acurácia para 99,9%. Demonstra-se, assim, que a precisão geométrica individual supera a necessidade de análise de fluxo temporal para sinais isolados.

C. Normalização e Invariância Cinemática

Um desafio crítico é a dependência da posição absoluta da mão no campo de visão [4]. Para resolver essa problemática, implementou-se uma técnica de normalização por translação de eixos via *NumPy*. Para cada amostra, o ponto referente ao carpo (*Landmark 0*) é estabelecido como a origem do sistema (0, 0, 0). Todas as demais coordenadas são recalculadas como vetores relativos a este ponto, garantindo que o modelo aprenda a morfologia da mão e não sua localização espacial.

D. Engenharia de Software e Acessibilidade

Diferentemente de trabalhos puramente experimentais, a inteligência do modelo foi integrada a uma interface funcional via *Streamlit*. O emprego da biblioteca *gTTS* para síntese de voz e de mecanismos de filtragem por persistência temporal preenche a lacuna entre a pesquisa acadêmica e a aplicação assistiva prática, cumprindo os objetivos de impacto social propostos.

III. METODOLOGIA

A metodologia deste trabalho estrutura-se em um pipeline modular composto por quatro estágios: (1) Aquisição de dados brutos, (2) Pré-processamento e Normalização Cinemática, (3) Modelagem Neural Profunda e (4) Integração de Interface e Acessibilidade. O fluxo foi projetado para assegurar que a inferência ocorra com latência inferior a 100ms, viabilizando a operação em tempo real.

A. Aquisição de Dados e Curadoria do Dataset

Diferentemente de abordagens que utilizam bases de dados públicas e genéricas, esta pesquisa fundamenta-se em um *dataset* autoral focado estritamente na geometria de marcos reguladores (*landmarks*).

- **Instrumentação:** Empregou-se a biblioteca *OpenCV* para a captura de vídeo e o *framework MediaPipe Hands* para a extração dos 21 marcos tridimensionais da mão.
- **Volume de Dados:** Coletou-se um total de 14.000 amostras (500 por classe do alfabeto), armazenadas em estrutura CSV. Cada amostra é representada por um vetor de 63 características (21 pontos $\times$ 3 coordenadas cartesianas $[x, y, z]$).
- **Rótulos (Labels):** As etiquetas foram processadas via *LabelEncoder (Scikit-Learn)*, mapeando os caracteres alfabéticos para um espaço numérico discreto compatível com a função de perda da rede.

B. Pré-processamento e Normalização Invariante ao Posicionamento

A principal barreira técnica em sistemas de visão computacional baseados em coordenadas é a dependência da posição absoluta da mão no plano da imagem. Para mitigar este problema, implementou-se uma técnica de **Normalização Cinemática por Translação de Eixo**, fundamentada na lógica de vetores relativos.

Utilizando a biblioteca *NumPy*, cada vetor de entrada X é submetido à seguinte transformação matemática:

$$P_i^{norm} = P_i - P_{pulso}, \quad \forall i \in \{0, \dots, 20\} \quad (1)$$

Onde P_{pulso} representa a coordenada do carpo (ponto 0). Esta operação redefine o pulso como a origem (0, 0, 0) do sistema local, tornando os dados invariantes à distância da câmera ou ao quadrante da imagem onde o sinal é executado. Após a translação, o vetor é planificado (*flatten*) para alimentar a camada de entrada da rede neural.

C. Arquitetura da Rede Neural (MLP)

A modelagem foi realizada por meio de uma rede neural *Multilayer Perceptron (MLP)* via *TensorFlow/Keras*. A escolha da MLP em detrimento de modelos recorrentes (LSTM) justifica-se pela natureza estática do alfabeto manual. Para tais sinais, a geometria instantânea provê informação suficiente para a classificação, permitindo a utilização de um modelo com menor custo computacional e maior velocidade de resposta.

A arquitetura (*Sequential Model*) é composta por:

- 1) **Camada de Entrada:** 63 neurônios correspondentes aos marcos normalizados.
- 2) **Blocos Densos Ocultos:** Três camadas densas com 128, 64 e 32 neurônios, respectivamente. Aplicou-se a função de ativação *ReLU (Rectified Linear Unit)* para introduzir não-linearidade e evitar a saturação de gradientes.
- 3) **Regularização e Estabilidade:** Implementou-se *Batch-Normalization* após cada camada para acelerar a convergência e *Dropout (0, 2)* para mitigar o *overfitting*, forçando a rede a extrair padrões morfológicos robustos.
- 4) **Camada de Saída:** Função *Softmax* para gerar uma distribuição de probabilidade sobre as 28 classes potenciais (alfabeto e caracteres especiais).

D. Procedimentos de Treinamento e Validação

O treinamento foi configurado com o otimizador *Adam* (taxa de aprendizado inicial $\eta = 0,001$) e a função de perda *Sparse Categorical Crossentropy*. Para garantir a integridade da validação e a capacidade de generalização, adotou-se a estratégia de **Divisão Estratificada (Stratified Train-Test Split)**, alocando 80% dos dados para treinamento e 20% para testes independentes.

IV. RESULTADOS E DISCUSSÃO

Os resultados experimentais demonstram que a arquitetura proposta atingiu um patamar de excelência em comparação à literatura recente, conforme sintetizado na Tabela I. A

convergência do modelo MLP foi obtida em 50 épocas, embora a estabilização da rede tenha sido observada precocemente, indicando uma alta separabilidade das classes no espaço de características tridimensionais.

TABLE I
COMPARAÇÃO DE PERFORMANCE E ARQUITETURA

Trabalho	Método	Dados	Acurácia
Alves et al. (2024)	CNN + Imagem	Skeleton 2D	92,1%
Kamble (2025)	LSTM	Temporal	86,7%
Este Trabalho	MLP + Landmarks	Geometria 3D	99,9%

A. Análise do Desempenho e Convergência

Conforme ilustrado na Fig. 1, as curvas de acurácia revelam um aprendizado acelerado nos primeiros 5 ciclos, nos quais os conjuntos de treinamento e validação ultrapassaram o limiar de 98%. Este comportamento assintótico é atribuído à extração de características de alta fidelidade provida pelo *MediaPipe*. Ao converter coordenadas espaciais brutas em vetores normalizados e invariantes, observou-se uma redução significativa na entropia dos dados de entrada, permitindo que as camadas densas identifiquem padrões morfológicos com baixo custo computacional.

A ausência de um *gap* expressivo entre as curvas de treino e teste ratifica a eficácia das camadas de *BatchNormalization* e *Dropout* (0, 2) na mitigação do *overfitting*. Nota-se na Fig. 1 uma oscilação transiente na acurácia de validação próxima à época 21; contudo, a resiliência do otimizador *Adam*, aliada aos *callbacks* de monitoramento, permitiu a rápida recuperação do sistema.

A estabilidade final do modelo valida a premissa de que a precisão geométrica instantânea (Geometria 3D) é mais determinante para o sucesso do reconhecimento de sinais estáticos do que o rastreamento temporal complexo. Tal escolha arquitetural resultou em um sistema substancialmente mais leve e veloz em comparação às implementações baseadas em redes recorrentes (LSTMs).




Fig. 1. Curvas de Acurácia e Perda por Época: observa-se a estabilização assintótica após a fase inicial de ajuste.

Para a otimização da superfície de erro e garantia de generalização, aplicaram-se dois mecanismos críticos:

- **EarlyStopping:** Atuou como mecanismo de salvaguarda, interrompendo o processo ao detectar a ausência de melhoria na perda de validação (*val_loss*) por 15 épocas

consecutivas e restaurando o melhor estado (*checkpoint*) de pesos.

- **ReduceLROnPlateau:** Realizou o refinamento da taxa de aprendizado (η) ao identificar platôs de convergência, permitindo que o modelo explorasse mínimos locais mais profundos e estabilizasse a acurácia em 99,9%.

B. Interface de Tradução e Síntese de Voz (TTS)

A implementação da interface foi realizada via *Streamlit*, visando a portabilidade do sistema. Para prover uma interação natural, desenvolveu-se um algoritmo de **Persistência de Confirmação**: um caractere é integrado à sentença apenas se a predição mantiver um limiar de confiança superior a 98% durante 15 quadros consecutivos.

Adicionalmente, implementou-se um temporizador de inatividade de 7 segundos para a detecção de encerramento de sentenças. Ao atingir este limite, o texto acumulado é processado pela biblioteca *gTTS* (*Google Text-to-Speech*), convertendo a tradução visual em síntese vocalizada via áudio *MP3* integrado ao navegador. Esta integração fecha o ciclo de acessibilidade, possibilitando uma comunicação bidirecional fluida.

V. CONCLUSÃO E TRABALHOS FUTUROS

A convergência entre a extração de marcos reguladores via *MediaPipe Hands* e o processamento por Redes Neurais Densas (MLP) demonstrou ser uma solução robusta e de alta eficiência para o reconhecimento do alfabeto manual de LIBRAS em tempo real. A principal contribuição técnica deste trabalho reside na implementação da normalização cinemática invariante centrada no carpo. Tal método neutralizou as variações de posicionamento relativo e biotipo do sinalizador — obstáculos críticos em sistemas de visão computacional *cross-dataset*, conforme observado na literatura [2].

Diferentemente de abordagens fundamentadas em janelas temporais extensas, como o sistema *SLRNet* [3], este estudo comprovou que, para sinais isolados e estáticos, a precisão da geometria instantânea processada por uma arquitetura MLP é superior. O modelo não apenas superou os índices de acurácia reportados em trabalhos correlatos, atingindo 99,9%, como também reduziu drasticamente a demanda por recursos computacionais. Essa otimização viabiliza a execução fluida em hardwares convencionais e dispositivos móveis, utilizando bibliotecas de baixa latência como *TensorFlow Lite* e *NumPy*.

As aplicações práticas desta solução são amplas, abrangendo desde ferramentas pedagógicas para o aprendizado de LIBRAS até interfaces de comunicação assistiva em serviços de atendimento público. A integração com síntese de voz via *gTTS* e a interface de usuário em *Streamlit* validam a viabilidade do sistema como um produto de acessibilidade funcional, reduzindo o hiato entre a teoria algorítmica e a inclusão social.

Como perspectivas futuras, planeja-se a expansão desta arquitetura para o reconhecimento de sinais dinâmicos complexos. Pretende-se investigar o emprego de mecanismos de *Self-Attention* e modelos baseados em *Transformers* para capturar dependências de longo prazo em sentenças contínuas.

Adicionalmente, a incorporação de marcos faciais (*Face Mesh*) possibilitará o processamento de expressões não manuais — elementos gramaticais indispensáveis para a tradução plena da LIBRAS — alinhando-se às tendências de multimodalidade discutidas em pesquisas recentes [4], [1].

REFERENCES

- [1] C. E. Alves, F. A. Boldt, and T. M. Paixão, “Enhancing Brazilian Sign Language Recognition through Skeleton Image Representation,” *arXiv preprint arXiv:2404.19148*, 2024.
- [2] A. Sarmento and M. Ponti, “A Cross-Dataset Study on the Brazilian Sign Language Translation,” in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV) Workshops*, 2021, pp. 2193–2202.
- [3] S. Kamble, “SLRNet: A Real-Time LSTM-Based Sign Language Recognition System,” *arXiv preprint arXiv:2506.11154*, 2025.
- [4] R. C. B. Rego, L. M. G. de Moraes, and W. M. Almeida, “Brazilian Sign Language Recognition Using Deep Learning Based on Fast Fourier Transform and Kinematic Features,” *IEEE Access*, vol. 13, pp. 202880–202892, 2025, doi: 10.1109/ACCESS.2025.3637779.