

Roteiro de Estudo e Desenvolvimento de Projeto Final - Inteligência Artificial II

Prezados alunos,

Este roteiro visa orientá-los no desenvolvimento do trabalho prático final da disciplina de Inteligência Artificial II, que culminará na entrega de um projeto prático e de um artigo científico. O objetivo é aplicar os conceitos e técnicas estudados em sala de aula em um problema real ou simulado de interesse.

A relevância do trabalho para esses temas será um critério de avaliação. Temas relacionados ou derivados dos trabalhados em sala podem ser utilizados.

Exemplos incluem: CNN's, RNN's, LSTM's, IA generativa, autoencoders, técnicas de embeddings, transformers, redes multimodais, neuroevolução, etc.

As notas serão avaliadas de maneira comparativa.

Número máximo de alunos: 3

Parte 1: Desenvolvimento do Projeto Prático

Passo a Passo para o Desenvolvimento da Pesquisa:

1. Definição do Problema e Escopo:

1.1. **Escolha do Tema:** Identificar um problema ou área de aplicação que possa ser abordada por alguma das técnicas de IA estudadas. Pensem em cenários do mundo real, conjuntos de dados disponíveis ou simulações interessantes.

Regras importantes:

- Alunos engajados em projetos ou grupos de pesquisa são incentivados a desenvolver trabalhos alinhados aos temas de seus respectivos projetos ou grupos.
- Datasets oriundos de problemas reais, técnicas experimentais, ou plataformas governamentais/institucionais terão maior peso. Datasets prontos ou disponíveis online terão menor relevância.
- É crucial pesquisar artigos relacionados ao tema e/ou à técnica que servirá de base para o desenvolvimento do trabalho.

1.2. **Relevância:** Justifiquem a importância do problema escolhido e como a aplicação de IA pode trazer uma solução.

1.3. **Definição dos Objetivos:** Estabeleçam claramente o que pretendem alcançar com o projeto. Quais são os resultados esperados?

1.4. **Definição do Escopo:** Delimitar o alcance do projeto para que seja factível dentro do tempo disponível.

2. Pesquisa Bibliográfica e Estado da Arte:

2.1. **Busca por Artigos:** A pesquisa aprofundada em bases de dados científicas é um passo crucial para o desenvolvimento de qualquer trabalho acadêmico. Para o tema escolhido, é imprescindível que vocês explorem as seguintes

plataformas: arxiv, IEEE Xplore, ACM Digital Library, Scopus, Web of Science e Google Scholar (pesquisem no google ou em IIm's, cuidado com alucinações das IIm's). Essas bases de dados são reconhecidas por abrigar um vasto acervo de artigos científicos revisados por pares, garantindo a qualidade e a relevância das informações encontradas.

- 2.2. O objetivo dessa pesquisa é identificar trabalhos que abordem problemas semelhantes aos que vocês pretendem investigar ou que utilizem metodologias relevantes para o desenvolvimento da pesquisa de vocês.
- 2.3. É **obrigatório** que vocês pesquisem e citem no mínimo **4 artigos científicos**. A seleção desses artigos deve ser criteriosa, priorizando aqueles que apresentem resultados significativos, discussões aprofundadas e que possam servir como base para a argumentação e o embasamento teórico do trabalho de vocês. A citação destes artigos deve seguir as normas do template do Latex.
- 2.4. **Análise Crítica:** Leiam e analisem os artigos encontrados, identificando as abordagens utilizadas, os resultados alcançados, as limitações e as lacunas existentes. Isso ajudará a posicionar o trabalho de vocês e a identificar possíveis inovações.

3. Seleção e Preparação dos Dados:

O desenvolvimento de um projeto de IA, seja supervisionado, semi-supervisionado ou não supervisionado, geralmente segue etapas metodológicas bem definidas para garantir a qualidade e a robustez dos resultados. Abaixo, detalhamos e expandimos os pontos cruciais mencionados, fornecendo um guia mais abrangente para a execução dessas fases.

- 3.1. **Aquisição de Dados:** A qualidade e a relevância dos dados impactam diretamente o desempenho do modelo.

3.2. Fontes:

- 3.2.1. **Dados Públicos:** Explore repositórios como Kaggle, UCI Machine Learning Repository, dados governamentais (ex: dados abertos de instituições públicas), ou bases de dados de pesquisas científicas. A vantagem é a facilidade de acesso, mas a desvantagem pode ser a falta de especificidade para o problema.
- 3.2.2. **Dados Coletados:** Se o projeto exigir informações específicas, a coleta direta pode ser necessária. Isso pode envolver sensores, formulários, web scraping (com devida atenção às leis de privacidade e termos de serviço), ou registros internos de uma organização. Este método oferece maior controle sobre a especificidade dos dados, mas demanda mais tempo e recursos.
- 3.2.3. **Dados Gerados Sinteticamente:** Em cenários onde dados reais são escassos, sensíveis ou difíceis de obter, a geração sintética pode ser uma alternativa. Isso pode ser feito através de simulações, modelos gerativos (como GANs), ou simplesmente duplicando e perturbando dados existentes de forma controlada. A desvantagem é que dados sintéticos podem não capturar toda a complexidade do mundo real.

Considerações: Tamanho do dataset, representatividade, viés dos dados, e

questões éticas (privacidade, consentimento).

IMPORTANTE: datasets reais terão maior relevância.

3.3. **Divisão dos Dados:** Para avaliar a capacidade de generalização do modelo, é fundamental dividir o conjunto de dados em subconjuntos distintos.

3.3.1. **Conjunto de Treinamento (Training Set):** Usado para treinar o modelo, ajustando seus parâmetros internos. Geralmente, a maior parte dos dados (ex: 70-80%).

3.3.2. **Conjunto de Validação (Validation Set):** Utilizado durante o treinamento para ajustar os hiperparâmetros do modelo e para monitorar o desempenho e evitar overfitting. Ajuda a fazer escolhas sobre o modelo (ex: número de neurônios em uma rede neural, tipo de kernel em SVM). A validação cruzada (Cross-Validation) é uma técnica comum para este fim, dividindo o conjunto de treinamento em vários "folds" para avaliação mais robusta.

3.3.3. **Conjunto de Teste (Test Set):** Um conjunto de dados completamente novo, não visto pelo modelo durante o treinamento ou validação. É usado apenas uma vez, no final do processo, para fornecer uma estimativa imparcial do desempenho do modelo em dados não vistos. É crucial para avaliar a capacidade de generalização do modelo para o mundo real.

3.3.4. **Estratificação:** Em casos de classes desbalanceadas (em problemas de classificação), é importante garantir que a proporção das classes seja mantida em cada subconjunto (treinamento, validação, teste) para evitar viés.

3.4. Aplicabilidade das Regras:

As etapas de **Aquisição de Dados, Pré-processamento e Divisão dos Dados** são universalmente relevantes para a maioria dos paradigmas de aprendizado de máquina, incluindo **aprendizado supervisionado** (onde há um conjunto de dados com rótulos de saída conhecidos para treinamento) e **aprendizado não supervisionado** (onde o objetivo é encontrar padrões ou estruturas nos dados sem rótulos de saída predefinidos).

4. Definição da Metodologia de Desenvolvimento:

4.1. **Escolha da Abordagem de IA:** A seleção da técnica de Inteligência Artificial é o pilar fundamental para o sucesso da resolução do problema. É crucial realizar uma análise aprofundada das características do problema em questão para determinar a abordagem mais adequada.

4.2. **Detalhes da Implementação:** As ferramentas e ambientes de desenvolvimento também devem ser listados. Além disso, é essencial detalhar as **bibliotecas e frameworks** específicos que serão empregados, como TensorFlow ou PyTorch para aprendizado profundo, Scikit-learn para aprendizado de máquina clássico, NumPy e Pandas para manipulação de dados, e Matplotlib ou Seaborn para visualização. A estrutura de dados, o pipeline de processamento e a

infraestrutura computacional necessária (hardware, CPUs, GPUs) também são elementos importantes a serem considerados nesta seção.

- 4.3. **Modelagem:** Esta seção é dedicada à arquitetura e representação interna da solução de IA. A abordagem baseada em **redes neurais**, é fundamental detalhar a arquitetura do modelo, especificando o tipo de rede (ex: feedforward, recorrente, convolucional), o número de camadas, o tipo de camadas (entrada, ocultas, saída), o número de neurônios por camada, as funções de ativação (ReLU, Sigmoid, Tanh, Softmax) e a conectividade entre elas.
- 4.4. **Parâmetros:** A definição e otimização dos parâmetros são críticas para o desempenho do modelo de IA. Nesta etapa, é necessário especificar os **parâmetros iniciais** do modelo, que podem incluir pesos e vieses para redes neurais. Além disso, devem ser definidos os **parâmetros de otimização** que guiarão o processo de treinamento ou busca da melhor solução. Isso pode envolver a taxa de aprendizado (learning rate) em redes neurais, o número de épocas de treinamento, o tamanho do batch, o tipo de otimizador (Adam, SGD), a probabilidade de mutação e cruzamento em algoritmos genéticos, ou o número máximo de iterações em algoritmos iterativos. É importante descrever como esses parâmetros serão ajustados e otimizados, seja por meio de técnicas de busca em grade (grid search), otimização bayesiana, ou validação cruzada, visando alcançar o melhor desempenho e generalização do modelo.
5. **Desenvolvimento e Implementação:**
 - 5.1. **Codificação:** Implementar a solução de acordo com a metodologia definida.
 - 5.2. **Treinamento/Execução:** Treinamento do modelo (se aplicável) ou execução do algoritmo.
 - 5.3. **Experimentação:** realização de experimentos variando parâmetros e configurações para encontrar a melhor performance.
6. **Definição da Metodologia de Validação e Análise dos Resultados:**
 - 6.1. **Métricas de Avaliação:** Escolham as métricas apropriadas para avaliar o desempenho do projeto (ex: acurácia, precisão, recall, F1-score para classificação; MSE, MAE para regressão; fitness para algoritmos genéticos).
 - 6.2. **Técnicas de Validação:** Descrevam como a validação será realizada (ex: validação cruzada k-fold, conjunto de teste separado).
 - 6.3. **Análise e Interpretação:** Analisem os resultados obtidos. Eles atendem aos objetivos iniciais? Quais são as limitações da solução? O que pode ser melhorado?

Parte 2: Elaboração do Artigo Científico

O artigo deverá adotar a estrutura padrão apresentada abaixo, onde os tópicos em negrito correspondem às seções do artigo, e os tópicos internos servem como orientações para a redação de cada parágrafo da respectiva seção.

1. **Introdução:**

Contextualização do problema.

Relevância do tema e justificativa do trabalho.
Objetivos do projeto (gerais e específicos).
Breve descrição da organização do artigo.

2. Trabalhos Relacionados:

Apresentação dos artigos científicos pesquisados que abordam problemas semelhantes ou técnicas relevantes.
Discussão comparativa das abordagens existentes, destacando suas vantagens e desvantagens.
Posicionamento do seu trabalho em relação à literatura existente, destacando sua contribuição ou diferencial. **Lembre-se de citar no mínimo 4 artigos.**

3. Metodologia:

Descrição detalhada do problema abordado.
Apresentação do conjunto de dados utilizado, incluindo sua origem, características e o processo de pré-processamento.
Descrição da abordagem de IA escolhida e o porquê de sua seleção.
Detalhamento da arquitetura do modelo ou do algoritmo implementado.
Especificação das ferramentas, linguagens e bibliotecas utilizadas.
Descrição clara da metodologia de desenvolvimento e validação utilizada no projeto.

4. Resultados:

Apresentação dos resultados obtidos de forma clara e concisa, utilizando tabelas, gráficos e outras representações visuais quando apropriado.
Discussão e interpretação dos resultados em relação aos objetivos do projeto e às métricas de avaliação definidas.
Comparação dos resultados com trabalhos relacionados, se aplicável.

5. Conclusão:

Recapitulação dos principais achados do trabalho.
Discussão sobre o cumprimento dos objetivos.
Limitações do projeto e desafios encontrados.
Sugestões para trabalhos futuros e possíveis extensões.

6. Referências.

Auxílio para escrita de artigos científicos pode ser encontrados neste excelente link, escrito pelo Prof. Maurício Acconcia:

<https://acconcia.medium.com/elabora%C3%A7%C3%A3o-de-tccs-6d308b5fc7da>

Template para desenvolvimento do artigo:

Na tela inicial do overleaf clique em “Modelos” é procure por “IEEE Conference Template” o que tem uma tag ‘Official’

A adequação do template também impactará nota dos alunos

Qualquer dúvida, estarei à disposição para auxiliá-los. Bom trabalho!